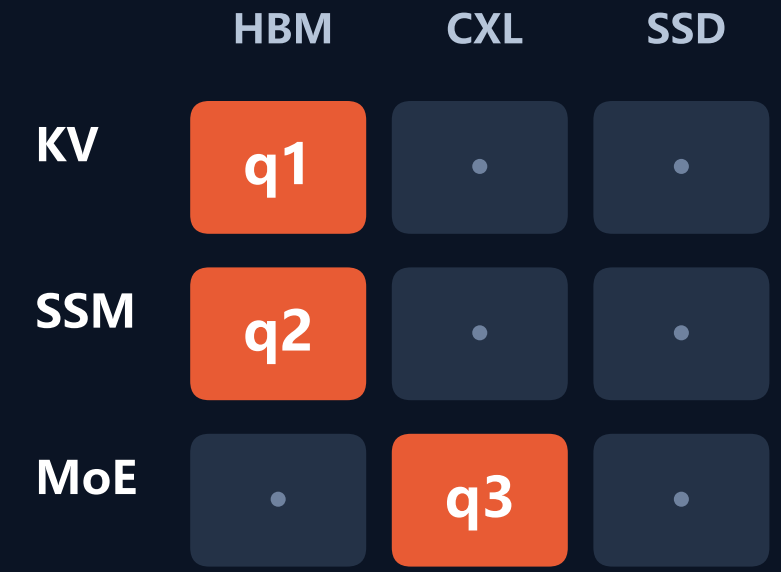
INCUBATION PROPOSAL

精度 × 驻留
混合大模型的联合优化

Precision–Placement Co-Optimization
for Hybrid LLM Inference

KV Cache · SSM 状态 · MoE 专家权重
HBM · CXL 附加内存 · SSD



示意：精度与位置共同决策
图中位宽及放置不代表最优解

固定资源与质量约束下，验证相对强基线
至少 15% 的有效吞吐增益

建议孵化：先证明联合决策的额外价值

战略匹配已经明确；创新机制与净收益需要用强基线验证。

WHY SK HYNIX

连接三层产品能力

以系统效率连接 HBM、CXL 内存与 SSD。

形成面向客户工作负载的配置依据与软件参考方案。

WHAT TO INCUBATE

统一分配精度与驻留

三类数据共同竞争快层容量和链路带宽。

优化跨对象的资源取舍，检验顺序决策留下的空间。

DECISION REQUEST

批准六个月验证

设立跨职能小组与有限测试资源。

通过阶段门决定是否进入 2027–2029 年产品协同路线。

立项命题：同样的资源与质量，能否通过联合优化产生 ≥15% 的净有效吞吐增益?

来源：S02–S03；本页立项建议为提案判断。

窗口已经打开：模型与内存系统正在共同变化

公开证据支持开展验证；市场份额、未来架构占比和产品量产节奏均未作预测。

模型侧

混合架构已有实例

S12

Nemotron 系列提供 Attention / Mamba / MoE 的真实混合模型场景。

系统侧

容量与访问共同约束

S01

三类数据的生命周期、读写模式与计算强度存在明显差异。

企业侧

系统协同已成公开方向

S02–S03

海力士展示 CXL 内存池、DRAM+SSD 混合内存及 KV 复用方案。

策略：以混合模型切入，并保留对 GQA / MLA / 其他递归状态结构的适配能力。

来源：S01–S03、S12；公开信息截至 2026-11-08。

三个数据对象，共享同一份快层预算

对象不同，收益和代价不同；独立优化容易忽略资源替代关系。

优化对象	内存行为	精度风险	分层机会
KV Cache	随上下文与并发扩张；活跃 KV 可能每步读取	层 / 头 / 数据块敏感性不同；长上下文需单独评估	活跃数据与可复用前缀分开管理
SSM 状态	每步读写；状态大小对序列长度固定、随并发增长	误差进入递归；影响随生成长度变化	活跃状态靠近计算；暂停状态可迁出
MoE 专家权重	基本只读；路由决定工作集，热度随负载变化	访问热度不等于量化敏感性	驻留 / 预取 / 缺失处理 / 混合精度

统一问题：一单位 HBM 容量，分给哪类数据、以什么精度保存，才能带来最大系统收益?

来源：S01、S10、S13；数据特征归纳。

联合决策空间：精度 × 位置，而非固定绑定

候选位宽取决于算子、设备与质量验证；表中仅示意策略空间。

量化配置 q_i	HBM 低延迟 / 高带宽	CXL 内存 容量扩展 / 共享	SSD 容量 / 持久化
较高精度	容量与质量取舍	传输与驻留取舍	访问时限与预取可行性
中等精度	容量与质量取舍	传输与驻留取舍	访问时限与预取可行性
较低精度	容量与质量取舍	传输与驻留取舍	访问时限与预取可行性

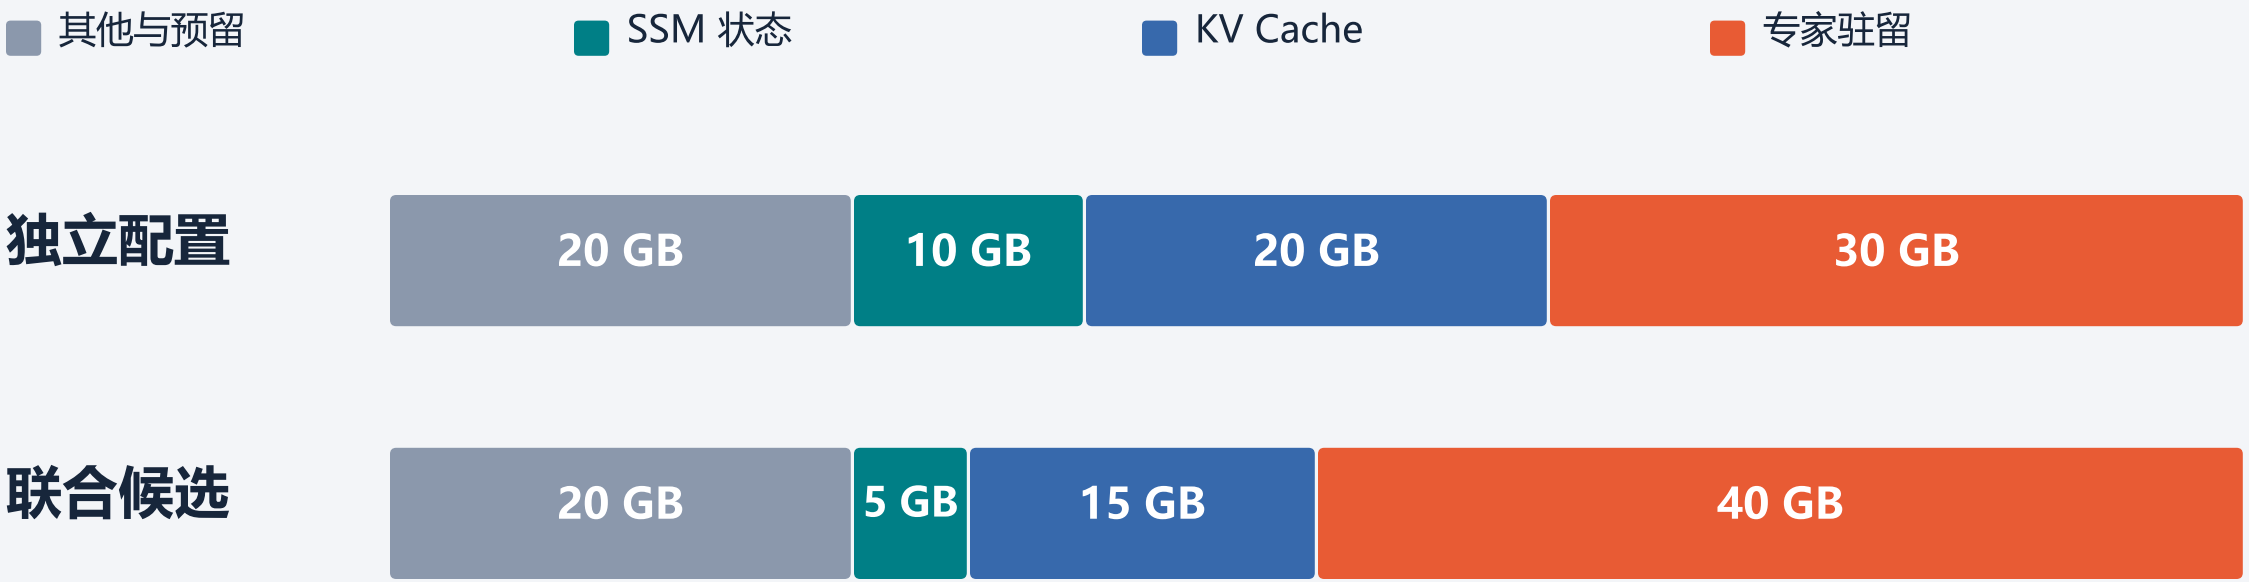
实际候选集须通过硬件与质量筛选

策略为每个对象选择可行的 (q_i, p_i)，并考虑迁移 / 预取开销与执行位置。

本页为方案设计；CXL 层指附加 DRAM / 内存池。

核心假设：跨对象释放容量，可能跨越性能阈值

说明性容量算例：总 HBM 预算固定为 80 GB；不代表任一模型测量结果。



待验证链条：KV / 状态压缩 → 释放 10 GB → 更多专家驻留 → 缺失流量下降 → 有效吞吐变化

关键实验：净收益能否覆盖质量损失、解量化、迁移、内核及调度开销？

全部数字为机制示意；未假设量化无损，也未推导吞吐收益。

相关工作密集：创新需要落在可检验的机制上

比较聚焦本轮核查的直接相关能力；不构成穷尽查新或专利结论。

相关工作	已覆盖能力	本提案需进一步证明
HOBBIT / SliceMoE	混合精度专家卸载、缓存或精度切片	跨对象共享预算的增量价值
TailorKV / StrataFlux	KV 量化与卸载；权重 / KV 的跨层精度补充	递归状态误差与驻留的耦合
CXL GPU–NDP MoE	HBM / CXL-NDP 专家分配 + 专家位宽	三类对象及 SSD 的统一资源模型
ITME / HyMCache	CXL / DRAM / SSD，权重或前缀 KV 分层	精度选择带来的额外优化空间
ReplaySSM / PACE	递归状态重构、周期更新或量化	状态质量预算对其他对象的影响

拟议贡献：统一边际收益模型 + 跨对象分配策略 + 实际在线开销与净收益验证。

来源：S04–S11；摘要及 S06 正文核查。

优化目标：固定资源下最大化有效吞吐

Goodput = 在规定质量与 TTFT / TPOT 服务时限内完成的输出 token / 秒。

$$\max \ \text{Goodput}(q, p, \pi \mid R, W)$$

q：精度配置　p：驻留 / 副本　π：迁移、预取与执行策略

≥15% 是验收假设

R 为固定资源；W 为预先登记的负载。
比较对象为同约束下的强基线。

容量约束

HBM / CXL / SSD 容量
副本、元数据、临时缓冲均计入

链路与计算约束

有效带宽、队列、设备可达性
内核精度支持与转换吞吐

质量与服务约束

关键任务非劣性 / 长生成质量
TTFT、TPOT 尾延迟与成功率

离线阶段求质量与成本画像；在线阶段执行有界开销的策略。

系统方案：离线画像 + 在线联合资源管理

第一阶段采用现有 GPU 与内存 / SSD；近存计算作为独立扩展配置评估。

离线画像与校准

质量敏感性
按对象 / 层 / 专家评估

平台成本模型
访问、转换、迁移与计算

候选策略库
可行精度与驻留组合

在线联合资源管理器

- 观测：并发、长度、路由、队列与命中
- 决策：快层容量与精度的统一分配
- 执行：驻留、预取、迁移与版本切换
- 保护：质量约束、最小驻留期与回退

HBM

GPU 执行 / 高价值驻留

CXL 内存

容量扩展 / 复用状态

SSD

后备容量 / 冷数据

主机 DDR / 页锁定缓冲、PCIe / CXL 拓扑和数据中转路径均纳入测量。

核心资产：可校准的成本模型、对象级遥测、低开销策略与推理框架连接器。

本页为拟议架构；CXL GPU 直达、DMA 与设备端计算均需按平台验证。

拟议策略：按净边际收益分配稀缺资源

先建立小规模可解释上界，再设计接近上界的在线策略。

01

生成可行候选

精度 × 驻留 × 访问路径
过滤不满足质量与内核支持的组合

02

评估净边际收益

收益：减少关键路径等待
成本：占用、迁移、转换与误差

03

统一预算分配

跨 KV / 状态 / 专家竞争容量
显式处理带宽与队列冲突

04

有界更新与回退

设置最小驻留期和收益门槛
负载漂移时重规划并安全切换

策略粒度建议：请求准入时定预算；阶段边界重规划；每步只执行轻量计数与预取。

验收重点：净收益相对强交替优化仍存在，并且控制开销低于其带来的节省。

统一优化框架，保留三类对象的不同语义

质量和数据正确性首先定义可行域，再在可行域中优化性能。

KV CACHE

按生命周期区分

活跃 KV 与可复用前缀分开。

稠密注意力的旧 KV 仍可能每步读取；SSD 需要预取或复用窗口。

检索、长上下文质量单独验证。

RECURRENT STATE

保护递归历史

活跃状态优先靠近执行单元。

低精度误差可能反复进入更新；提高位宽不能恢复丢失历史。

暂停状态与检查点允许迁出。

EXPERT WEIGHTS

热度与敏感性分开

推理权重只读，便于保留主副本。

使用热度决定驻留价值，使用质量画像决定量化容忍度。

副本与精度切片计入真实容量。

统一的是资源分配目标；状态一致性、误差传播与访问时限必须分别建模。

设计依据：S05–S07、S10–S13。

15% 必须来自联合决策，并经强基线验证

所有对比保持同一质量门槛、资源预算、服务时限、预热条件与输入序列。

编号	比较方案	它排除的替代解释
B0	固定精度 + 静态放置	提供可复现参考，不单独用于证明创新
B1 / B2	只优化精度 / 只优化放置	判断单一维度是否已解释全部收益
B3	双顺序 + 充分调优的交替优化	排除仅因执行顺序或调参不足形成的优势
B4	最接近方法的适用实现 / 组合基线	与相关先进方法比较，明确兼容范围及改动
J / U	联合策略 / 小规模离线上界	量化可实现收益与剩余优化空间

主要基线 B*：B1–B4 中满足同等约束的最强可复现方案；不得只选 B0。

实验覆盖：模型、内存压力与负载动态

在实验前登记主测试集合；完整报告有收益、无收益和性能退化的场景。

维度	建议设置	要验证的问题
模型	至少 2 个混合模型；1 个 Attention–MoE 对照	收益是否依赖某单一结构?
上下文 / 生成	8K / 32K / 128K 输入，短与长生成；按模型支持筛选	KV 与递归状态瓶颈如何变化?
并发与路由	低 / 高并发、路由漂移、多轮与暂停恢复	在线策略是否稳定?
资源配置	工作集可驻留、接近阈值、明显溢出；固定各层容量	收益来自哪里，何时消失?
硬件路径	真实 CXL + NVMe；GPU 访问 / 中转路径分别测量	仿真是否与可部署路径一致?

分组报告：容量受限场景的主 KPI，与可完全驻留场景的性能回归边界。

模型候选：S01、S12；具体 checkpoint 与内核支持在 G0 锁定。

预先定义验收：主指标、约束与归因同时通过

建议标准，须在 G0 与评审共同锁定；此处没有项目实测结果。

PRIMARY KPI

+15%

相对 B* 的有效吞吐增益

主测试集配对比值的几何均值 ≥1.15；95% 置信区间下界 >1.00。

质量	关键任务逐项非劣性；容差与评测集预登记。长检索、推理及长生成单列。
服务	满足约定 TTFT / TPOT 尾延迟与成功率要求；不以放宽 SLO 换吞吐。
归因	分别消融跨对象预算、精度选择、驻留和预取；控制开销完整计入。
部署	主结论以实测支持；仿真与预测单列，能耗 / TCO 仅在可测范围报告。

通过门槛：效应量、统计可信度、质量和服务约束均成立；不以单次峰值代替验证。

六个月 incubation：用阶段门降低投入不确定性

先判断优化空间，再判断可实现性，最后判断部署价值。

G0 第 1–6 周

锁定问题与上界

模型 / 质量 / SLO / B* 锁定
真实路径校准与瓶颈画像
小规模离线上界

G1 第 7–12 周

验证联合机制

可运行联合策略
对比强顺序与交替基线
消融与在线开销测量

G2 第 13–24 周

验证净收益与部署

至少 2 个混合模型
真实 CXL / SSD 与负载漂移
质量、尾延迟和回退验证

停止 / 转向条件：上界不足、收益被开销抵消，或质量与服务约束无法同时满足。

G2 通过后再申请产品化投入；若仅单对象有效，收缩为对应专项。

2027–2029：从机制验证走向产品协同

以下为拟议研发路线；后续阶段均以此前阶段证据与合作条件为前提。

2027 — **证明机制**

联合策略 + 可校准模型

输出：测评方法、参考实现、适用边界
决策：≥15% 净增益是否可复现

2028 — **联合原型**

设备接口 + 框架连接器

输出：CXL / SSD 遥测与提示接口
决策：客户工作负载与成本是否获益

2029 — **参考方案**

配置指南 + 客户验证

输出：软硬件参考架构与部署规范
决策：生态接入、维护成本与商业可行性

长期资产：工作负载画像、质量—成本模型、设备接口与跨平台验证能力。

战略背景：S02–S03；年份与交付物均为本提案建议。

资源申请：小团队、可复现平台、明确伙伴边界

建议配置用于六个月验证；预算与设备规格在 G0 按实际可用资源核定。

PEOPLE

4–5 人跨职能小组

算法 / 量化：1 人
推理系统与内核：2 人
平台与性能工程：1 人
项目 / 产品协同：兼职或 1 人

PLATFORM

有限规模真实测试

GPU 服务器与固定 HBM 预算
真实 CXL 内存及 NVMe SSD
可记录带宽 / 功耗的工具链
框架、模型与数据访问条件

PARTNERS

对接客户与生态

海力士：器件特性与系统模型
加速器 / OEM：拓扑与驱动
推理框架：接口与内核接入
客户：负载、质量与 SLO

商业评估：每百万合格 token 成本、配置采用率与产品组合价值；不假设 HBM 需求必然增长。

本轮申请：六个月人力与验证资源 + 阶段评审机制 + 指定业务 / 技术对接人。

批准孵化，验证一个明确的系统命题

Precision–Placement Co-Optimization for Hybrid LLM Inference

同样的资源与质量，
联合分配精度与位置，能否创造更高的有效吞吐?

研究对象	KV Cache / SSM 状态 / MoE 权重
优化维度	量化精度 × HBM / CXL / SSD 驻留
证据标准	相对强基线 ≥15% 净增益，满足质量与 SLO

请求决策：批准六个月 PoC，按 G0 / G1 / G2 证据决定继续、收缩或停止。

附录 A｜精度、驻留与执行路径的离散决策模型

用于小规模离线分析与上界估计；在线实现不要求直接运行完整优化器。

决策变量	$x_{i,k} \in \{0,1\}$：对象 i 是否采用候选配置 k
候选配置 k	位宽、位置、副本、计算 / 传输路径及版本
容量约束	$\sum_i \sum_k x_{i,k} \cdot bytes_{i,k,t} \le capacity_t$
选择约束	$\sum_k x_{i,k} = 1$；副本作为候选配置整体计价
目标与评估	以执行模拟 / 实测估计服务 goodput，并验证质量

非线性来自真实系统

- 质量对位宽的非线性响应
- 容量命中与溢出的阈值
- 并发、队列与流水重叠
- 跨对象质量与路由交互

可用查表与分段近似求解；质量代理函数必须用端到端任务重新验证。

附录 B | 何时可能超过 15%，何时不会

简化延迟算例仅说明条件，不代表吞吐预测，也不能替代端到端实验。

总延迟下降比例 ≈ f × r − o

f：基线关键路径搬运等待占比　r：被消除的比例　o：新增开销占原总延迟比例

假设场景	f	r	o	延迟变化
等待明显且可减少	40%	50%	3%	下降 17%
搬运已经不重要	10%	50%	3%	下降 2%

仅在固定串行服务假设下，延迟下降 17% 对应约 20.5% 速率提升；生产 goodput 须实测。

附录 C | 主要技术风险与对应实验

每个风险对应一个可观测指标和阶段内处理方式。

风险	识别方式	处理 / 决策
SSM 递归误差	长生成、状态漂移、任务质量	限制状态候选；检查点 / 残差方案单独计价
CXL 路径不成立	平台可达性、有效带宽、中转开销	先测真实路径；不成立则改拓扑或调整范围
SSD 暴露关键延迟	缺失次数、P99、预取覆盖率	限制活跃对象下沉；采用可行恢复窗口
转换与策略开销	内核时间、重规划时间、迁移流量	离线候选库、收益门槛与驻留滞回
收益只在单一场景	全矩阵结果、消融、负载漂移	明确适用边界；必要时转为单对象专项
缺少商业差异	客户负载与配置成本敏感性	围绕设备接口、合作接入和参考配置形成资产

SSD 写放大、耐久度、数据版本一致性与副本成本，在实测原型中纳入评估。

附录 D | 证据索引：战略、模型与直接相关工作

完整链接与证据边界见 SOURCES.md；PPT 演讲者备注包含对应链接。

S01	NOVA	混合负载与近存计算背景
S02–S03	SK hynix Future Forum / OCP 2026	系统协同与 CXL / SSD 公开布局
S04–S05	HOBBIT / TailorKV	专家与 KV 的量化 + 卸载
S06–S07	CXL GPU–NDP MoE / SliceMoE	专家位宽、放置和精度切片
S08–S09	ITME / HyMCache	CXL、DRAM、SSD 与 KV 复用
S10–S11	ReplaySSM / StrataFlux	递归状态与跨层精度表示
S12–S13	Nemotron 3 Ultra / PACE	混合模型实例与状态量化

证据边界：来源证明方向与已有能力；本项目创新、15% 收益和商业结果均需另行验证。

资料为公开来源；预印本结论需结合其评估方法理解。

附录 E | 评审问答：把主张收敛到可证伪的假设

建议以机制、证据和决策条件回答，避免用优化空间大小替代实验结果。

为什么不只做专家缓存?	先证明状态 / KV 的预算调整能改变专家驻留及端到端表现；否则收缩项目。
普通 CXL 与 CXL-NDP 是否一样?	分别建模。基础原型不依赖设备端计算，NDP 作为独立扩展。
15% 有保证吗?	没有。它是相对强基线的拟议目标，通过离线上界和真实原型逐步验证。
创新会不会只是组合?	用强交替基线及跨对象消融检验；没有额外机制收益就不作强创新主张。
为什么值得海力士做?	把器件特性、软件策略与客户负载连接，形成配置依据和设备接口需求。

评审原则：允许假设失败，但必须通过可复现实验清楚解释结果。