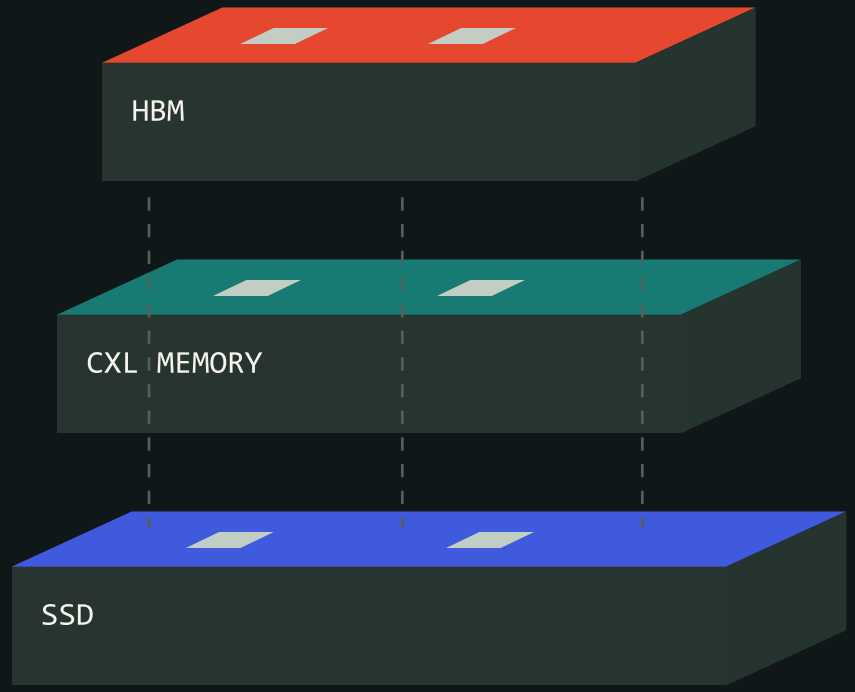
精度与位置，一起决定推理效率

面向 KV Cache、SSM 状态与 MoE 权重的混合精度 × 分层放置联合优化

PRECISION × PLACEMENT

在既定资源与质量约束下，寻找超过 15% 的净有效吞吐增益。



HBM / CXL-ATTACHED DRAM / SSD

评审讨论稿 / 2026.11 / ≥15% 为拟议验证目标，尚无本项目实测结果

把内存组合，变成可验证的系统优势

01 资源已经齐备

HBM、CXL 内存与 SSD 构成快层到容量层的产品基础。

02 系统决策仍有空间

何种数据值得占用 HBM，取决于精度、访问代价与质量敏感性。

PROPOSED VALIDATION TARGET

15%+

固定资源与质量，相对强基线的净增益

六个月验证机制，
阶段门决定后续投入。

战略背景：S02–S03；15% 为拟议验收目标。

模型与内存都在演进，联合优化进入验证窗口

已有混合模型与跨层设备可作为验证基础；未来架构占比不作确定性预测。

MODEL

Attention + Mamba + MoE

Nemotron 3 Ultra 提供混合架构的真实模型实例。

S12

ARCHITECTURE

三种访问行为共存

NOVA 刻画不同算术强度，状态、KV 与专家需求各异。

S01

ECOSYSTEM

全栈内存系统已展示

海力士公开展示 CXL 池化、DRAM+SSD 与 KV 复用。

S02–S03

来源：S01–S03、S12；企业展示不等同于所有功能已量产。

三类数据，三种访问规律，一个 HBM 预算

01 / KV CACHE

上下文越长，缓存越大

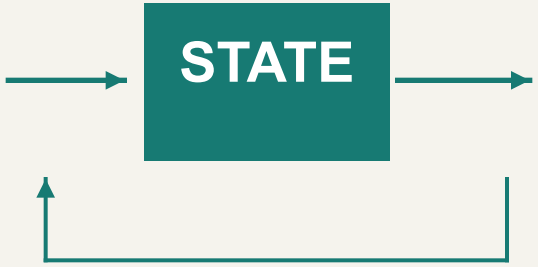


历史序列持续扩展

活跃 KV 可能每步读取；
可复用前缀具有不同生命周期。

02 / SSM STATE

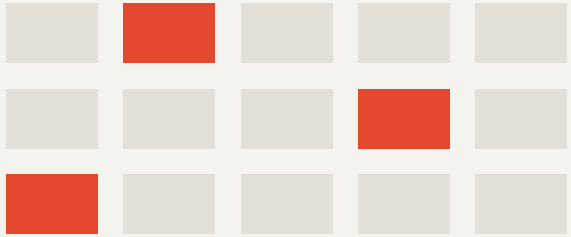
每步更新，误差可递归



状态随并发增长；
活跃状态优先靠近执行单元。

03 / MoE WEIGHTS

稀疏激活，驻留价值不均



仅少数专家被路由激活

基本只读，工作集动态变化；
热度与量化敏感性分别测量。

特征依据：S01、S10、S13；图形为访问模式示意。

两次局部最优，不保证组合后的系统最优

精度改变大小、流量与内核代价；位置改变访问时限与驻留收益。

SEQUENTIAL DECISIONS

q 先确定量化 → p 再安排放置 → ? 系统效果

JOINT PRECISION–PLACEMENT

	HBM	CXL	SSD
q-A	**候选**	候选	候选
q-B	候选	候选	**候选**
q-C	候选	**候选**	候选

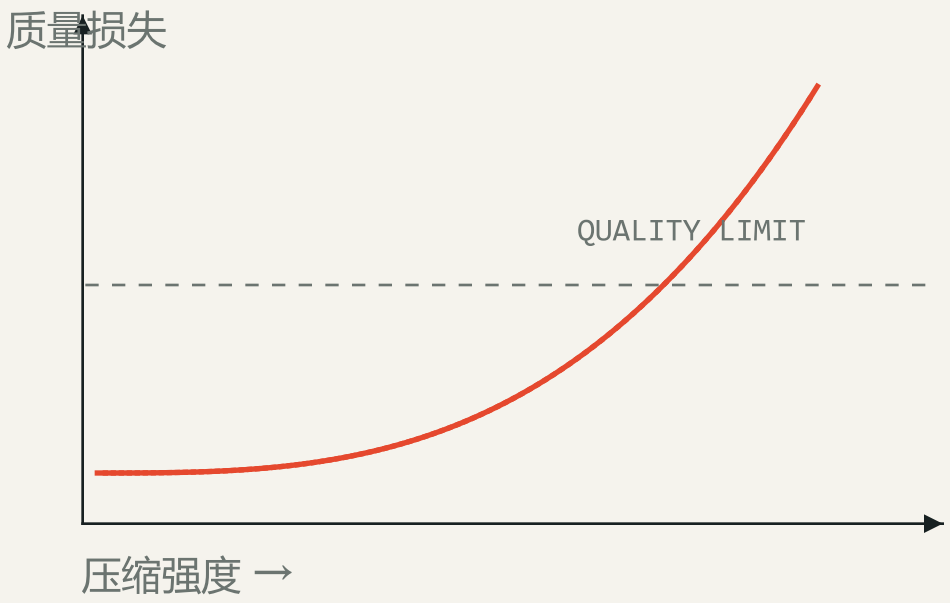
二维候选示意：位宽与位置共同搜索，实际可行域须筛选。

统一比较：一单位快层容量，换来多少净收益？

把质量、容量、传输与执行开销放进同一个决策。

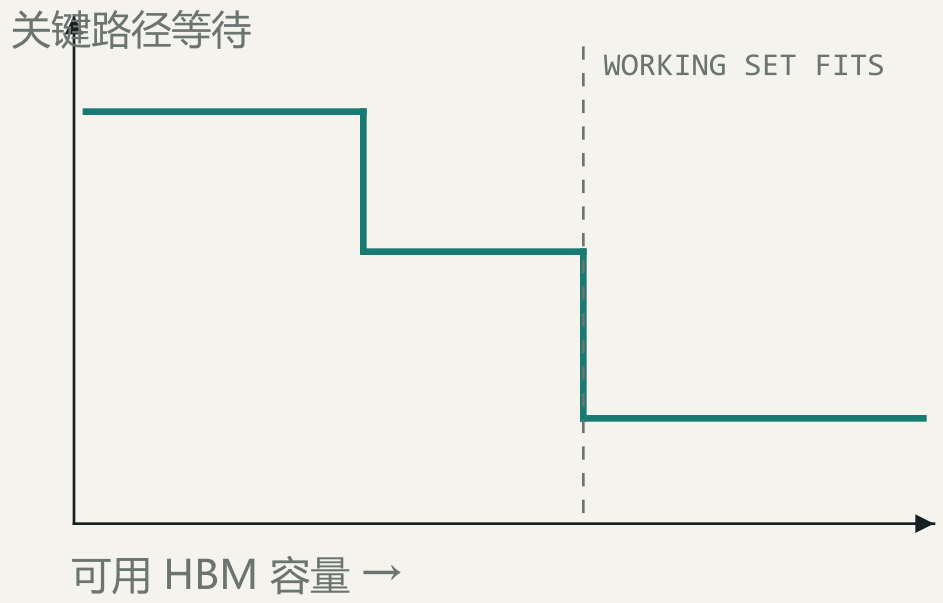
两条非线性，共同决定可行与最优的边界

QUALITY RESPONSE



压缩更激进，质量损失可能越过容忍边界

CAPACITY THRESHOLD

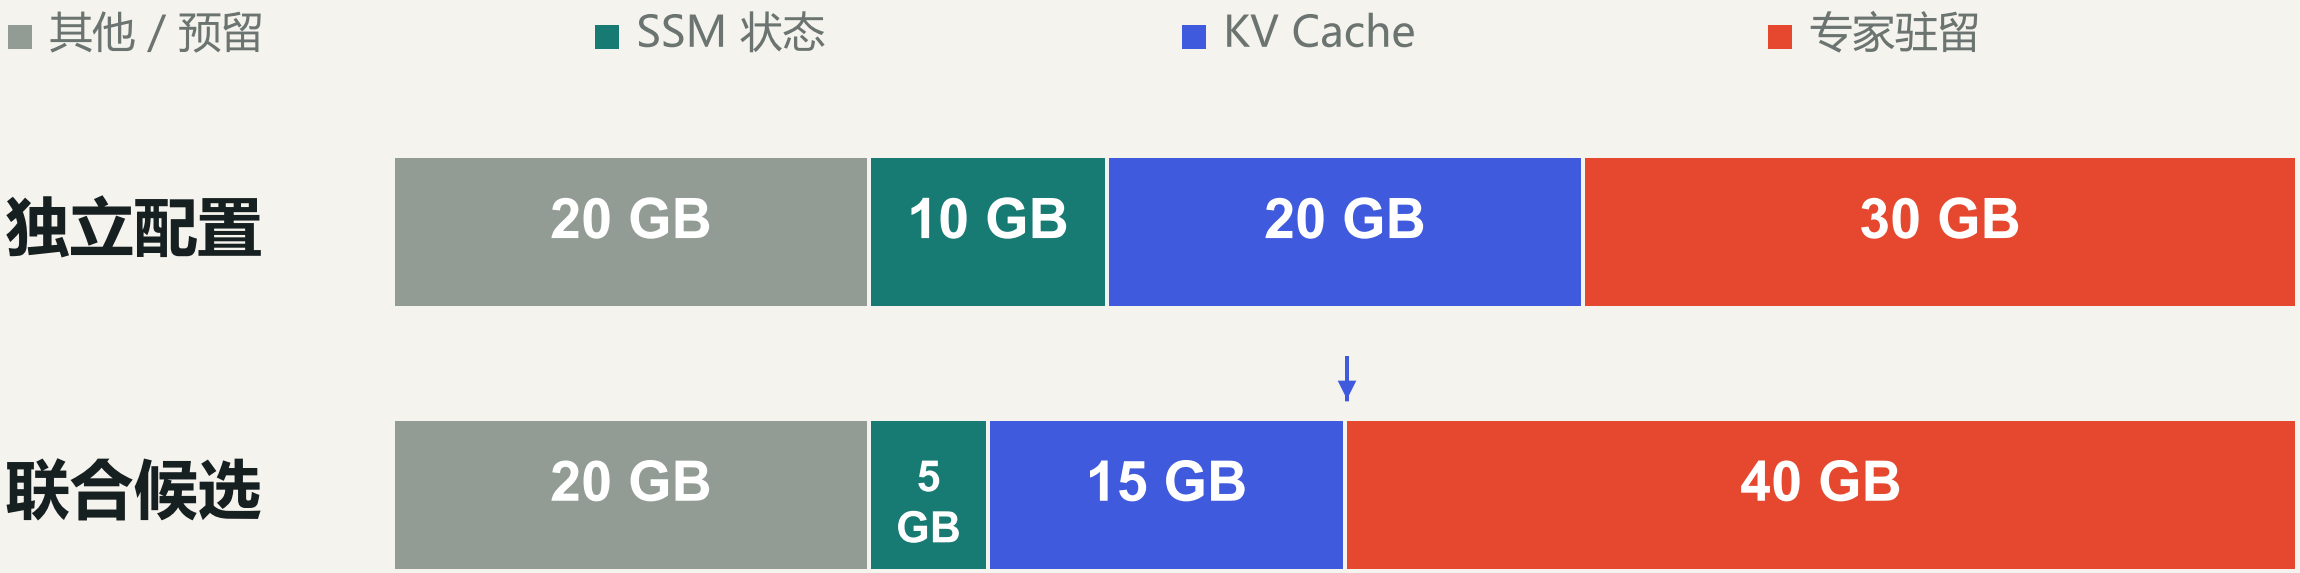


多释放一点容量，可能消除一整组缺失

概念图：曲线形状仅用于解释机制，不对应测量数据或拟合结果。

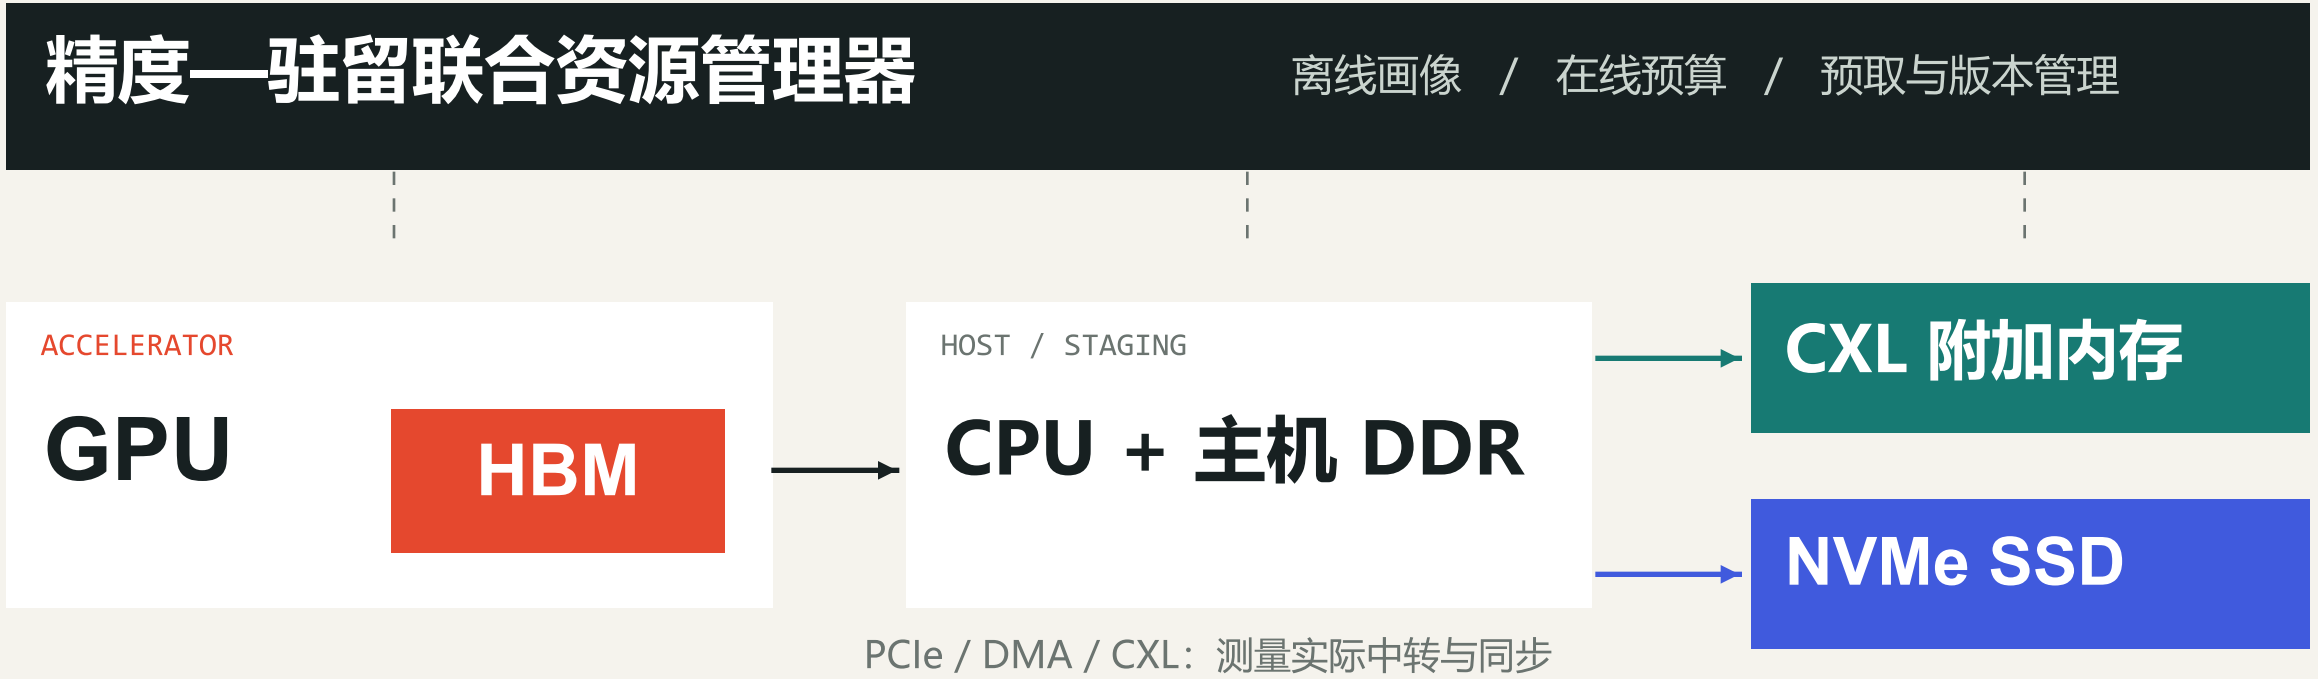
压缩 KV 或状态，收益可能出现在专家执行

说明性容量算例：固定 80 GB HBM。数字用于解释跨对象取舍，不代表具体模型实测。



释放 10 GB → 增加专家驻留 → 降低缺失流量 → 测量最终有效吞吐

用一个资源管理器，连接模型需求与真实数据路径



第一阶段复用现有硬件；近存计算可作为后续独立配置，不作为基础可行性的前提。

提案架构：普通 CXL 扩展与 CXL-NDP 分开评估；GPU 直达能力按平台核验。

目标只有一个：约束内的有效吞吐最大化

QUALITY-CONSTRAINED RESOURCE ALLOCATION

$$\max \ \text{Goodput}(q, p, \pi)$$

q 精度配置　　p 驻留与副本　　π 迁移、预取及执行策略

固定资源

容量、带宽、计算与临时缓冲

质量约束

关键任务、检索与长生成非劣性

服务约束

TTFT / TPOT 尾延迟与成功率

离线找边界，在线做有界开销的联合决策

拟议方法：先建立小规模优化上界，再决定在线近似策略。

01

画像

质量敏感性
设备与路径代价

→

02

分配

比较跨对象净收益
分配精度与快层容量

→

03

执行

预取、驻留与迁移
版本一致性与回退

→

04

反馈

热度与队列变化
达到阈值再重规划

FEEDBACK / HYSTERESIS

已有局部组合；待证明的是跨对象的额外价值

选取直接相关工作定位研究边界；不作穷尽查新或专利性结论。

EXISTING RESEARCH

专家精度 + 驻留
HOBBIT / SliceMoE / CXL GPU–NDP MoE

KV 精度 + 卸载
TailorKV / StrataFlux

CXL + DRAM + SSD
ITME / HyMCache

递归状态管理
ReplaySSM / PACE

PROPOSED CONTRIBUTION

统一净边际收益
同一容量与带宽预算下比较三类对象。

跨对象联合分配
量化一个对象，让另一个对象获益。

可执行的在线策略
强基线、完整开销与端到端质量验证。

来源：S04–S11；具体论文的原型 / 仿真边界见来源文件。

15%+，相对最强可复现基线，而不是静态分层

相同资源、质量门槛、服务时限与预热条件；在实验前登记测试集合。

15%+

拟议主指标：
满足质量与时限的有效吞吐增益

报告重复测量与置信区间，
完整保留无收益及退化场景。

单维度最优

只优化精度 / 只优化放置

强交替与顺序优化

双顺序充分调参，排除执行顺序优势

相关先进组合基线

在适用范围内实现，明确兼容差异

B* = 满足同等约束的上述最强方案

六个月，用三道证据门决定是否继续

申请验证窗口；产品化投入以真实原型、净增益与客户价值证据为前提。

1–6 周

G0

瓶颈与上界

锁定模型、质量与服务门槛
校准真实硬件与访问路径
估计联合优化的可行上界

7–12 周

G1

机制与原型

实现联合策略与强基线
消融跨对象预算和精度选择
计入控制、转换与迁移成本

13–24 周

G2

净收益与部署

至少两个混合模型
真实 CXL / SSD 与动态负载
验证有效吞吐、质量和尾延迟

三年沉淀：从优化策略，走向产品组合的系统能力

2027

验证机制

质量—成本画像
可复现原型与适用边界

2028

协同接口

设备遥测与策略提示
推理框架 / OEM 联合验证

2029

客户参考方案

配置指南与成本模型
持续适配模型和硬件

商业验证：每百万合格 token 成本、客户采用率、产品组合价值与维护投入。

战略背景：S02–S03；2027–2029 为建议路线，不代表公司量产或投资承诺。

批准六个月孵化，验证联合优化的系统价值

先证明净增益。
再扩大产品投入。

6
个月 / PoC

人员	建议 4–5 人：量化 / 系统与内核 / 平台性能
平台	GPU + CXL 内存 + NVMe SSD，测量真实路径
决策	G0 / G1 / G2：继续、收缩或停止

附录 / 实验协议与归因设计

模型与负载	≥2 个混合模型；Attention–MoE 对照；短 / 长上下文与生成
资源压力	可完全驻留 / 接近容量阈值 / 明显溢出；固定容量与有效带宽
动态场景	低 / 高并发，路由漂移，多轮复用，暂停与恢复
验收建议	主集配对比值几何均值 ≥1.15；95% CI 下界 >1.00
质量与服务	关键任务逐项非劣性；TTFT / TPOT 尾延迟与成功率预登记
归因消融	移除跨对象预算、精度选择、驻留或预取，分别测量开销

附录 / 哪些配置必须从可行域排除

SSM 状态

递归误差不可逆

简单升位宽不能恢复历史；主状态 / 残差 / 检查点均计价。

CXL 路径

GPU 可达性须验证

普通扩展、GPU DMA、主机复制及 CXL-NDP 分别建模。

SSD 访问

容量不等于访问可行

活跃对象下沉需满足读取时限；计入排队、写放大和耐久。

精度副本

存储收益须真实

多精度副本、元数据与临时缓冲完整计入预算。

依据：S05–S07、S10、S13；原型必须测量具体平台能力。

附录 / 超过 15% 的必要条件是什么

延迟下降 ≈ f × r − o

f 关键路径搬运等待占比 / r 消除比例 / o 新增开销占原延迟比例

等待明显且可削减	**40% × 50% − 3%**	**17%**
搬运不是主要瓶颈	**10% × 50% − 3%**	**2%**

简化说明性算例；不代表实测结果、goodput 预测或普适阈值。

附录 / 研究依据与证据边界

S01	**NOVA**	混合负载与近存计算
S02–S03	**SK hynix Future Forum / OCP**	系统战略与公开展示
S04–S05	**HOBBIT / TailorKV**	量化与专家 / KV 卸载
S06–S07	**CXL GPU–NDP MoE / SliceMoE**	专家位宽与驻留
S08–S09	**ITME / HyMCache**	CXL、DRAM 与 SSD 分层
S10–S11	**ReplaySSM / StrataFlux**	递归状态与跨层精度
S12–S13	**Nemotron 3 Ultra / PACE**	模型实例与状态量化

完整 URL 与结论边界见 SOURCES.md；文献数字不能相加，也不是本项目的实测收益。