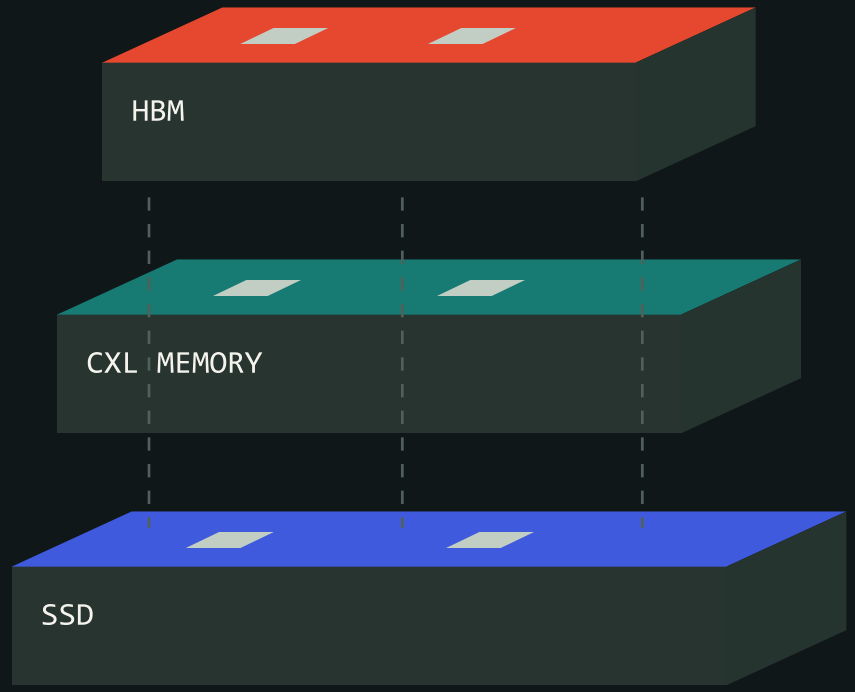
精度与位置，一起决定推理效率

面向 KV Cache、SSM 状态与 MoE 权重的
混合精度 × 分层放置联合优化

PRECISION × PLACEMENT

**在既定资源与质量约束下，
寻找超过 15% 的净有效吞吐增益。**



HBM / CXL-ATTACHED DRAM / SSD

评审讨论稿 / 2026.11 / ≥15% 为拟议验证目标，尚无本项目实测结果

把内存组合，变成可验证的系统优势

01 资源已经齐备

HBM、CXL 内存与 SSD 构成快层到容量层的产品基础。

02 系统决策仍有空间

何种数据值得占用 HBM，取决于精度、访问代价与质量敏感性。

PROPOSED VALIDATION TARGET

15%+

固定资源与质量，相对强基线的净增益

六个月验证机制，
阶段门决定后续投入。

战略背景：S02–S03；15% 为拟议验收目标。

行业变化：模型能力扩展，带来更多状态与权重管理

长上下文、稀疏专家与持续服务同时存在；内存需求由多种数据共同决定。

LONG CONTEXT

1M

token 上下文

Nemotron 3 Ultra 的模型报告展示百万 token 上下文。
历史 KV 的容量与访问需管理。

[S12] NVIDIA / 模型论文 · 2026.06.12

SPARSE MODEL

550B

总参数 / 55B 激活

同一混合模型具有大量未同时激活的专家参数。
计算稀疏不消除权重驻留需求。

[S12] NVIDIA / 模型论文 · 2026.06.12

SERVING SYSTEM

KV

成为服务调度对象

Mooncake 与 Dynamo 将复用、传输和分层缓存纳入推理服务架构。

[S22] Mooncake / 论文 · v5 2026.10

来源：S12（2026-06）、S22（2024/2026）、S21（2025-03）；指标为特定模型 / 系统实例。

跨层状态管理，已经进入服务架构与产品交付

从服务论文、平台软件到 SSD 产品应用，内存与存储协同具有明确的落地信号。



图示对象：可复用 / 非活跃的上下文数据；活跃数据的下沉仍须满足访问时限。

2024

Mooncake

服务论文

PD 分离与 KV-centric 调度，
利用 CPU、DRAM、SSD 缓存。

[S22] Mooncake · v1 2024.06

2025

NVIDIA Dynamo

官方平台功能

分布式 KV 管理与 NIXL，
连接 GPU、主机与存储层。

[S21] NVIDIA 技术博客 · 2025.03.18

2026

Micron SSD

公司出货自述

7600 / 9650 SSD 面向
客户 KV-cache 应用出货。

[S20] Micron FY26 Q4 · 2026.09.30

来源：S22 / Mooncake；S21 / NVIDIA Dynamo；S20 / Micron Product Highlights。

三星：软件、器件、认证与协同研发连续推进

四个公开里程碑显示能力投入；历史事件用于展示路径，不代表 2026 年最新代际排名。

2021

SMDK

软件公告

智能分层引擎 / API；
公开仓库见 S18。

[S14] Samsung SMDK · 2021.10.07

2023

CXL 2.0

器件开发

128GB CXL DRAM 开发；
支持内存池。

[S23] Samsung CXL · 2023.05.12

2024

Red Hat

基础设施认证

CXL 验证环境；
CMM-D / SMDK 演示。

[S15] Samsung / Red Hat · 2024.06.25

2026

zHBM

研发方向

直接 3D 堆叠；
Distributed I/O；
与 AI 芯片协同设计。

[S16] Samsung zHBM · 2026.10.29

2026 Q3 公司公告：扩大 HBM4 销售并响应服务器 SSD 需求 [S17]；zHBM 仍属研发方向 [S16]。

来源：S14 / 2021-10；S23 / 2023-05；S15 / 2024-06；S16–S17 / 2026-10-29。

竞争维度扩展：产品组合与系统协同都值得比较

以下为公开行动的并列梳理，不是性能横评，也不对未检索到的能力作缺失判断。

SAMSUNG

软件与协同研发

HBM4 / SSD 组合 [S17]
CMM-D / SMDK 软件与认证
zHBM 协同研发 [S16]

[S15] 官方认证公告 · 2024.06.25

[S16] zHBM / 在研发 · 2026.10.29

MICRON

平台关联的产品交付

HBM4 / Gen6 SSD
SOCAMM2 平台关联方案
KV-cache 应用出货自述

[S19] GTC 产品量产公告 · 2026.03.16

[S20] FY26 Q4 产品要点 · 2026.09.30

SK HYNIX

内存中心系统展示

MARS / CXL 内存池
DRAM+SSD 混合内存
KV Cache 共享与复用

[S03] OCP 系统展示 · 2026.10.16

[S02] Future Forum 战略 · 2026.09.09

提案定位：在既有产品与生态上，验证“质量感知精度 × 驻留”能否创造可部署的差异化。

来源：三星 S15–S18；美光 S19–S20；海力士 S02–S03。

项目必要性：把更多硬件选择，变成客户可测的收益

需求端

长上下文与混合模型，
使状态与专家资源取舍更复杂。

S12 / S21 / S22

供给端

快层、扩展内存和 SSD，
增加了配置与访问路径选择。

S03 / S19 / S20

竞争端

软件接口、客户验证与协同设计，
已成为公开投入方向。

S15 / S16 / S18

STRATEGIC INFERENCE

海力士需要回答：同样的资源与质量，怎样配置更有价值？

项目产出：质量—成本模型、
精度与驻留策略、设备提示接口，
以及客户负载的实测证据。

本轮投资判断：先用六个月验证增量收益；通过后再扩大合作与产品化投入。

事实依据：S03、S12、S15–S16、S18–S22；右侧为提案分析与待验证目标。

三类数据，三种访问规律，一个 HBM 预算

01 / KV CACHE

上下文越长，缓存越大

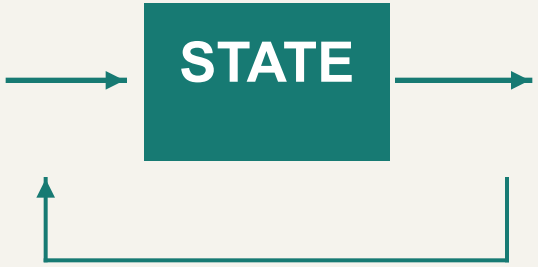


历史序列持续扩展

活跃 KV 可能每步读取；
可复用前缀具有不同生命周期。

02 / SSM STATE

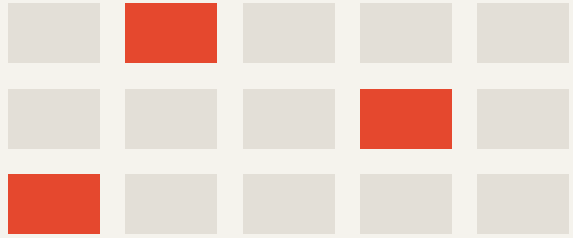
每步更新，误差可递归



状态随并发增长；
活跃状态优先靠近执行单元。

03 / MoE WEIGHTS

稀疏激活，驻留价值不均



仅少数专家被路由激活

基本只读，工作集动态变化；
热度与量化敏感性分别测量。

特征依据：S01、S10、S13；图形为访问模式示意。

两次局部最优，不保证组合后的系统最优

精度改变大小、流量与内核代价；位置改变访问时限与驻留收益。

SEQUENTIAL DECISIONS

q 先确定量化 → p 再安排放置 → ? 系统效果

JOINT PRECISION–PLACEMENT

	HBM	CXL	SSD
q-A	**候选**	候选	候选
q-B	候选	候选	**候选**
q-C	候选	**候选**	候选

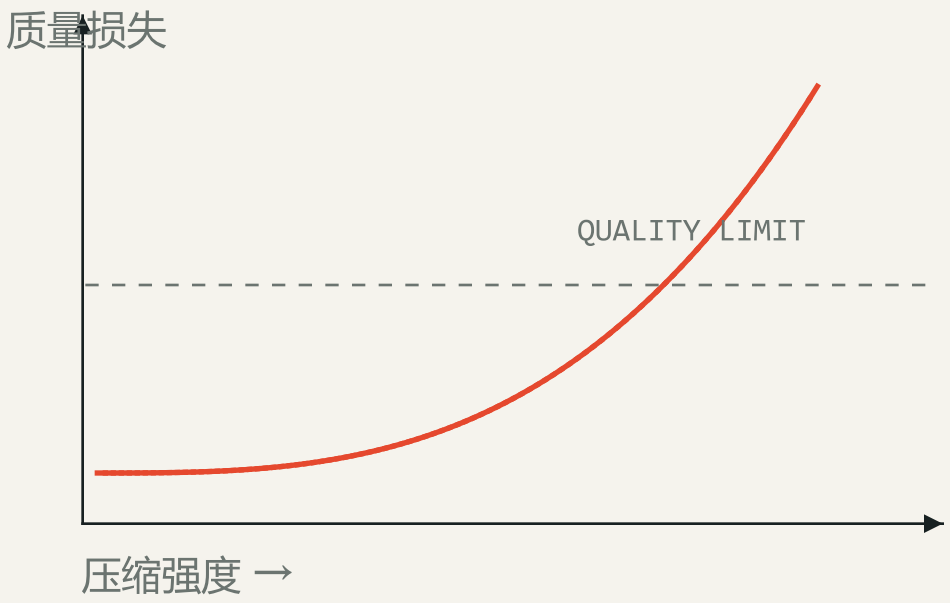
二维候选示意：位宽与位置共同搜索，实际可行域须筛选。

统一比较：一单位快层容量，换来多少净收益？

把质量、容量、传输与执行开销放进同一个决策。

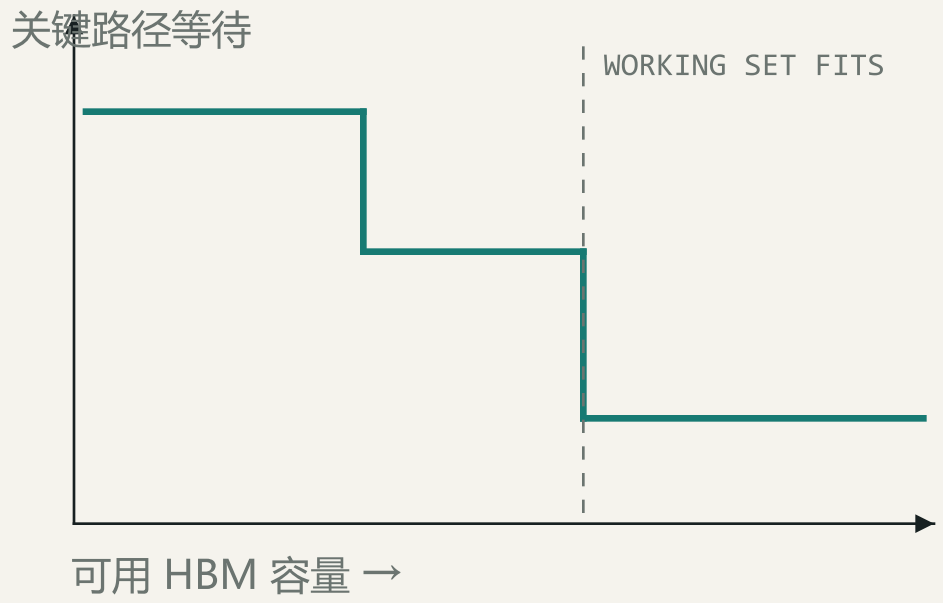
两条非线性，共同决定可行与最优的边界

QUALITY RESPONSE



压缩更激进，质量损失可能越过容忍边界

CAPACITY THRESHOLD

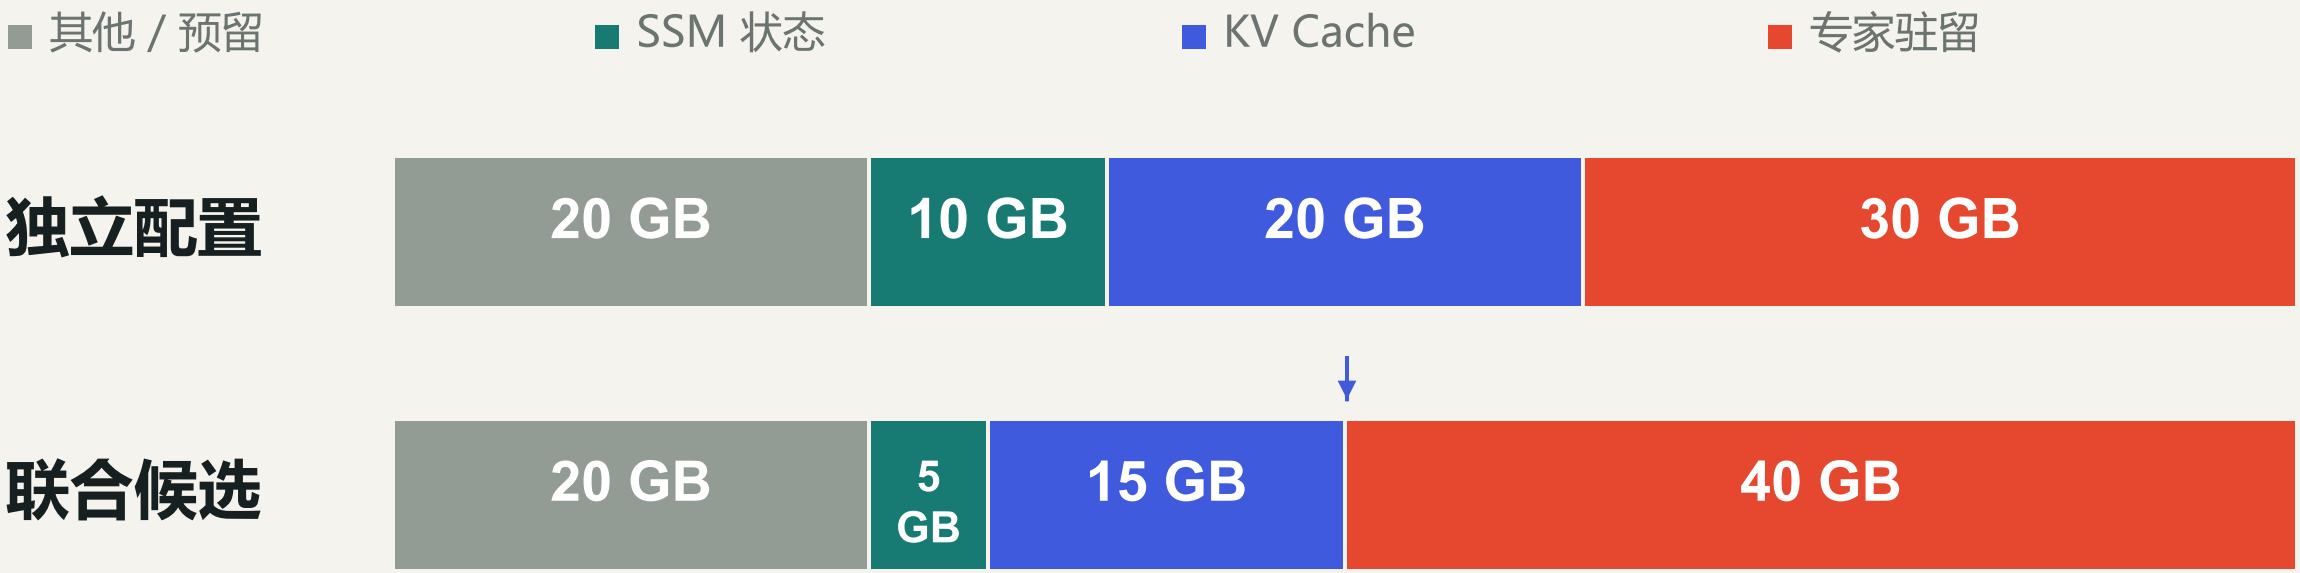


多释放一点容量，可能消除一整组缺失

概念图：曲线形状仅用于解释机制，不对应测量数据或拟合结果。

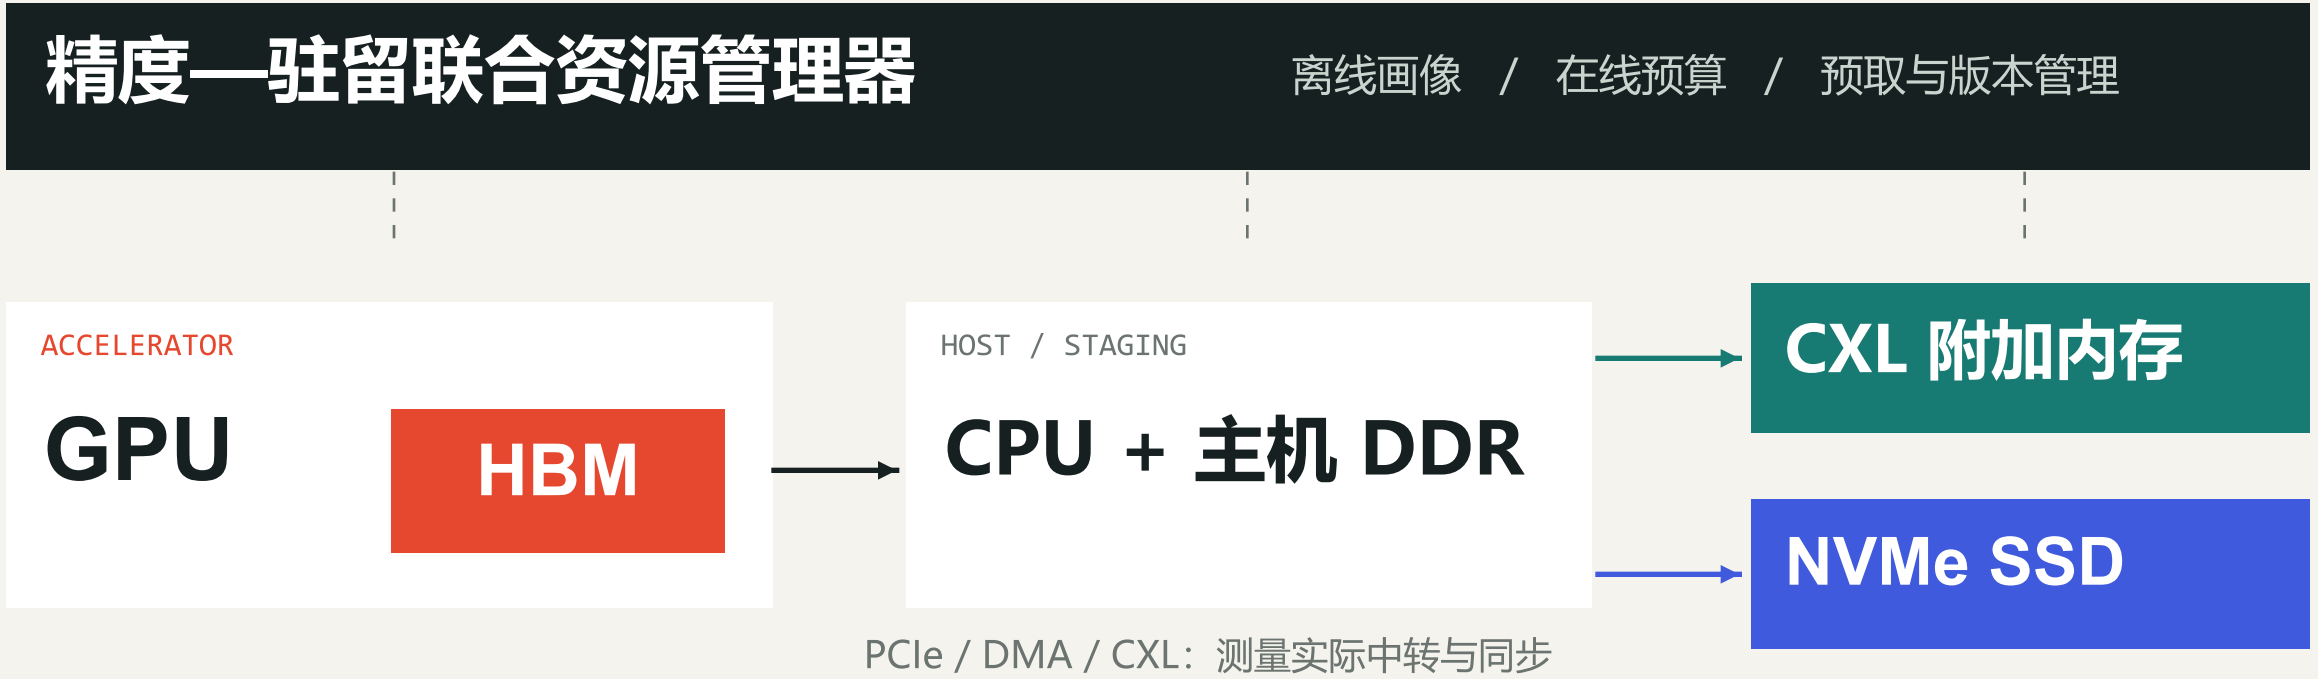
压缩 KV 或状态，收益可能出现在专家执行

说明性容量算例：固定 80 GB HBM。数字用于解释跨对象取舍，不代表具体模型实测。



释放 10 GB → 增加专家驻留 → 降低缺失流量 → 测量最终有效吞吐

用一个资源管理器，连接模型需求与真实数据路径



第一阶段复用现有硬件；近存计算可作为后续独立配置，不作为基础可行性的前提。

提案架构：普通 CXL 扩展与 CXL-NDP 分开评估；GPU 直达能力按平台核验。

目标只有一个：约束内的有效吞吐最大化

QUALITY-CONSTRAINED RESOURCE ALLOCATION

$$\max \ \text{Goodput}(q, p, \pi)$$

q 精度配置　　p 驻留与副本　　π 迁移、预取及执行策略

固定资源

容量、带宽、计算与临时缓冲

质量约束

关键任务、检索与长生成非劣性

服务约束

TTFT / TPOT 尾延迟与成功率

离线找边界，在线做有界开销的联合决策

拟议方法：先建立小规模优化上界，再决定在线近似策略。

01 画像

质量敏感性
设备与路径代价

→

02 分配

比较跨对象净收益
分配精度与快层容量

→

03 执行

预取、驻留与迁移
版本一致性与回退

→

04 反馈

热度与队列变化
达到阈值再重规划

FEEDBACK / HYSTERESIS

已有局部组合；待证明的是跨对象的额外价值

选取直接相关工作定位研究边界；不作穷尽查新或专利性结论。

EXISTING RESEARCH

专家精度 + 驻留
HOBBIT / SliceMoE / CXL GPU–NDP MoE

KV 精度 + 卸载
TailorKV / StrataFlux

CXL + DRAM + SSD
ITME / HyMCache

递归状态管理
ReplaySSM / PACE

PROPOSED CONTRIBUTION

统一净边际收益
同一容量与带宽预算下比较三类对象。

跨对象联合分配
量化一个对象，让另一个对象获益。

可执行的在线策略
强基线、完整开销与端到端质量验证。

来源：S04–S11；具体论文的原型 / 仿真边界见来源文件。

15%+，相对最强可复现基线，而不是静态分层

相同资源、质量门槛、服务时限与预热条件；在实验前登记测试集合。

15%+

拟议主指标：
满足质量与时限的有效吞吐增益

报告重复测量与置信区间，
完整保留无收益及退化场景。

单维度最优

只优化精度 / 只优化放置

强交替与顺序优化

双顺序充分调参，排除执行顺序优势

相关先进组合基线

在适用范围内实现，明确兼容差异

B* = 满足同等约束的上述最强方案

六个月，用三道证据门决定是否继续

申请验证窗口；产品化投入以真实原型、净增益与客户价值证据为前提。

1–6 周

G0

瓶颈与上界

锁定模型、质量与服务门槛
校准真实硬件与访问路径
估计联合优化的可行上界

7–12 周

G1

机制与原型

实现联合策略与强基线
消融跨对象预算和精度选择
计入控制、转换与迁移成本

13–24 周

G2

净收益与部署

至少两个混合模型
真实 CXL / SSD 与动态负载
验证有效吞吐、质量和尾延迟

三年沉淀：从优化策略，走向产品组合的系统能力

2027

验证机制

质量—成本画像
可复现原型与适用边界

2028

协同接口

设备遥测与策略提示
推理框架 / OEM 联合验证

2029

客户参考方案

配置指南与成本模型
持续适配模型和硬件

商业验证：每百万合格 token 成本、客户采用率、产品组合价值与维护投入。

战略背景：S02–S03；2027–2029 为建议路线，不代表公司量产或投资承诺。

批准六个月孵化，验证联合优化的系统价值

先证明净增益。
再扩大产品投入。

6
个月 / PoC

人员	建议 4–5 人：量化 / 系统与内核 / 平台性能
平台	GPU + CXL 内存 + NVMe SSD，测量真实路径
决策	G0 / G1 / G2：继续、收缩或停止

附录 / 实验协议与归因设计

模型与负载	≥2 个混合模型；Attention–MoE 对照；短 / 长上下文与生成
资源压力	可完全驻留 / 接近容量阈值 / 明显溢出；固定容量与有效带宽
动态场景	低 / 高并发，路由漂移，多轮复用，暂停与恢复
验收建议	主集配对比值几何均值 ≥1.15；95% CI 下界 >1.00
质量与服务	关键任务逐项非劣性；TTFT / TPOT 尾延迟与成功率预登记
归因消融	移除跨对象预算、精度选择、驻留或预取，分别测量开销

附录 / 哪些配置必须从可行域排除

SSM 状态

递归误差不可逆

简单升位宽不能恢复历史；主状态 / 残差 / 检查点均计价。

CXL 路径

GPU 可达性须验证

普通扩展、GPU DMA、主机复制及 CXL-NDP 分别建模。

SSD 访问

容量不等于访问可行

活跃对象下沉需满足读取时限；计入排队、写放大和耐久。

精度副本

存储收益须真实

多精度副本、元数据与临时缓冲完整计入预算。

依据：S05–S07、S10、S13；原型必须测量具体平台能力。

附录 / 超过 15% 的必要条件是什么

延迟下降 ≈ f × r − o

f 关键路径搬运等待占比 / r 消除比例 / o 新增开销占原延迟比例

等待明显且可削减	**40% × 50% − 3%**	**17%**
搬运不是主要瓶颈	**10% × 50% − 3%**	**2%**

简化说明性算例；不代表实测结果、goodput 预测或普适阈值。

附录 / 研究依据与证据边界

S01	**NOVA**	混合负载与近存计算
S02–S03	**SK hynix Future Forum / OCP**	系统战略与公开展示
S04–S05	**HOBBIT / TailorKV**	量化与专家 / KV 卸载
S06–S07	**CXL GPU–NDP MoE / SliceMoE**	专家位宽与驻留
S08–S09	**ITME / HyMCache**	CXL、DRAM 与 SSD 分层
S10–S11	**ReplaySSM / StrataFlux**	递归状态与跨层精度
S12–S13	**Nemotron 3 Ultra / PACE**	模型实例与状态量化

完整 URL 与结论边界见 SOURCES.md；文献数字不能相加，也不是本项目的实测收益。

附录 / 行业与竞争证据索引 1/2

来源 ID 可点击；完整标题、URL、原文节选与适用边界见 SOURCES_V3.md。

S14 **Samsung SMDK 软件发布**
2021-10-07

S23 **Samsung CXL 2.0 DRAM 开发**
2023-05-12

S15 **Samsung × Red Hat：CXL 认证环境**
2024-06-25

S16 **Samsung zHBM：研发中的系统协同**
2026-10-29

S18 **OpenMPDK / SMDK 公开仓库**
访问 2026-11-08；持续更新仓库

核查日期 2026.11.08。公告状态、认证 / 演示、研发方向分别解释；未引用市场份额或财务预测。

来源：S14、S23、S15、S16、S18；核查日期 2026-11-08。

附录 / 行业与竞争证据索引 2/2

来源 ID 可点击；完整标题、URL、原文节选与适用边界见 SOURCES_V3.md。

S17	**Samsung 2026 Q3：HBM / SSD 组合**	2026-10-29
S19	**Micron：HBM4 / Gen6 SSD / SOCAMM2**	2026-03-16
S20	**Micron：KV-cache 应用 SSD 出货自述**	2026-09-30
S21	**NVIDIA Dynamo：分层 KV 与 NIXL**	2025-03-18
S22	**Mooncake：KV-centric 服务论文**	v1 2024-06-24；v5 2026-10-08

核查日期 2026.11.08。公告状态、认证 / 演示、研发方向分别解释；未引用市场份额或财务预测。

来源：S17、S19、S20、S21、S22；核查日期 2026-11-08。